

# 大数据分析

# 实验报告之一

# (2019 年度春季学期)

| 姓 | 名_  | 朱明彦        |
|---|-----|------------|
| 学 | 号_  | 1160300314 |
| 学 | 院 _ | 计算机学院      |
| 教 | 师 _ | 杨东华、王金宝    |

计算机科学与技术学院

大数据分析实验报告

# 目录

| 第1章 | 实验目的                 | 3 |
|-----|----------------------|---|
| 第2章 | 实验环境                 | 3 |
| 第3章 | 实验过程及结果              | 3 |
| 3.1 | 项目架构                 | 3 |
|     | 3.1.1 Master 及其子类    | 3 |
|     | 3.1.2 Worker 及其子类    | 4 |
|     | 3.1.3 Vertex 及其子类    | 5 |
|     | 3.1.4 Communication  | 6 |
|     | 3.1.5 Combiner 类及其子类 | 6 |
| 第4章 | 实验心得                 | 7 |

## 实验三 图数据分析

### 第1章 实验目的

掌握大图数据计算平台的原理、架构和工作机制,理解大图计算平台的各项功能,包括数据载人、大图数据划分原理和大图计算。能够编写大图数据计算平台中的常用图分析方法 (PageRank, SSSP) 程序。

### 第2章 实验环境

- Ubuntu 16.04.5
- Java 1.8.0 181

### 第3章 实验过程及结果

#### 3.1 项目架构

#### 3.1.1 Master 及其子类

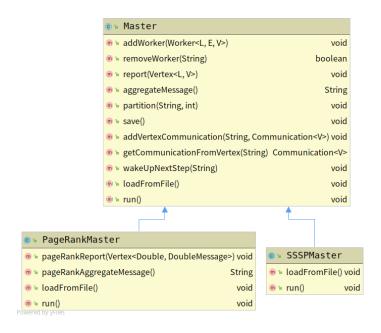


图 3.1: Master 及其子类 UML 图

对于 Master 与其子类,模拟的是 BSP 模型中 Master 节点。其中需要处理的问题主要有完成所有 worker 中每个顶点的计算、在所有的顶点之间进行通信两个功能。在实现时以 Master 为抽象类,其中最为重要的抽象函数即 run(),对于不同的应用如 SSSP 和 PageRanking,只需要重写 run()函数来完成其相应逻辑即可,master 包中的继承关系如图3.1所示。

对于 Master 类,其定义时共有三个泛型参数,分别为 L, 顶点类型; E, 边类型; V, 消息类型,对于 SSSP 问题,其只需将对应的泛型参数改为 Integer, Integer, IntMessage 即可。对于 Master 类中设计的函数及其功能如下:

- addWorker, removeWorker 分别用于在 Master 类中增加删除 worker。
- report, aggregateMessage 主要用于全局的消息的 aggregate, 具体参见节。
- partition 用于将图进行划分,其中的两个参数分别为图源文件路径以及划分的数量。
- save 用于将 partition 的结果存储到外存中,每个划分一个源文件,每一条输出类似  $u, v_0, v_1 \dots, v_n$ ,其中 u 为源点, $v_i$  为 u 的所有出边的目的点,分隔符为 tab。
- addVertexCommunication, getCommunicationFromVertex 分别用于增删每个顶点对应的 communication, 关于 communication 详见3.1.4节。
- wakeUpNextStep 是将发送消息的接收节点在下一轮唤醒(转为 active 状态)。

对于 SSSPMaster 和 PageRankMaster 而言,其 run 函数具有很大的相似性(即进行 BSP 过程的模拟),本质上都是一轮轮执行 Worker,直到所有的 Worker 都结束,再将每个顶点的计算结果输出至外存中进行保存;不同在于对于 PageRanking 应用,只需要将所有的 Vertex 保持 active 状态,执行指定轮数即可,而对于 SSSP 应用则对每个 Worker 的状态进行判断,并在下一轮开始之前将利用 wakeUpNextStep 唤醒的 worker 转人工作状态。

#### 3.1.2 Worker 及其子类

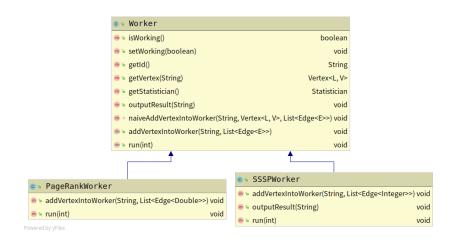


图 3.2: Worker 及其子类 UML 图

对于 Worker 及其子类,模拟的是 BSP 模型中的 Worker 节点,在其中需要维护每个 Vertex 的出边、消息队列(包括两个接收队列和一个发送队列,在本项目中利用 Communication 来实现,详见3.1.4节)。并且在接收到 Master 发送的消息后,串行在每个节点上执行 compute 函

数,并将有更新的 Vertex 的产生的消息发送到对应的出边目的顶点即可。worker 包中的继承关系如图3.2所示。

对于 Worker 类,其定义时共有三个泛型参数,分别为 L, 顶点类型; E, 边类型; V, 消息类型, 对于 SSSP 问题, 其只需将对应的泛型参数改为 Integer, Integer, IntMessage 即可, PageRanking 问题同理。在 Worker 类中设计函数及其功能如下所示:

- run(int) 用于在 Worker 上对其中的每个 Vertex 串行的执行 compute 函数。
- 一系列的 getter 和 setter 函数。

对于 SSSPWorker 而言,其 run 函数需要对其中每个当前接收队列不为空的 Vertex 执行 compute 函数,并将执行后为 active 的顶点,将更新后的信息发送至所有的出边的目的点;而 对于 PageRankWorker 而言,其 run 函数相对简单,只需要在第 0 轮 super step 利用对应的 aggregator 统计顶点的数目,在剩余轮数中对所有的顶点执行 compute。

#### 3.1.3 Vertex 及其子类

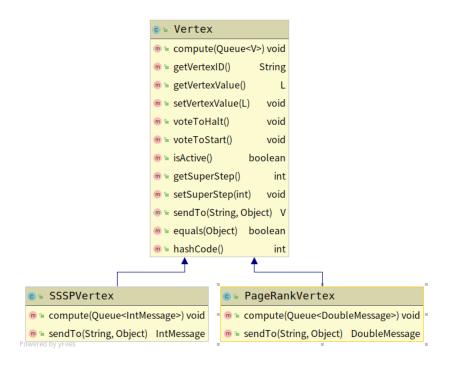


图 3.3: Vertex 及其子类 UML 图

对于 Vertex 及其子类,模拟的是 BSP 模型中的 Vertex, 其中基本类(抽象类) Vertex 不参与运算,对于不同的应用分别重写 compute 函数即可。其中 Vertex 有 2 个泛型参数,分别是 L, 顶点类型; V, 消息类型。vertex 包中的继承结构如图3.3所示。

Vertex 中设计的函数及其功能如下:

• compute 即该顶点的需要执行的计算函数,对于不同的应用需要重写。

- sendTo 用于产生该顶点需要发送的消息并将其返回,使用对应的 worker 进行发送。
- 一系列 getter 和 setter 函数等。

对于 SSSPVertex 的 compute 函数需要比较所有的接收消息中,是否存在比当前顶点的属性更小的信息,如果是则更新并将该顶点转为 active 状态,否则则将该顶点转为 inactive 状态。对于 PageRankVertex 的 compute 计算,只需要在其中计算所有接收消息中值的和,然后在 worker 中计算  $value = 0.15/verticesNumber + 0.85 \times sum$  [1]。

#### 3.1.4 Communication

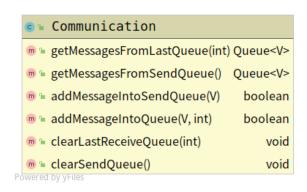


图 3.4: CommunicationUML 图

项目中实现 Communication 功能使用 Communication 类实现,其中有一个泛型参数 V,消息类型,有两个接收队列和一个发送队列,在使用时根据当前 superStep 的轮数确定使用哪一个队列作为当前的接收队列(模 2 的结果进行选择)。通过 Master 和 Worker 维护每个 Vertex 和其对应的 Communication 实例,来实现对于发送和接收消息过程的模拟。

#### 3.1.5 Combiner 类及其子类

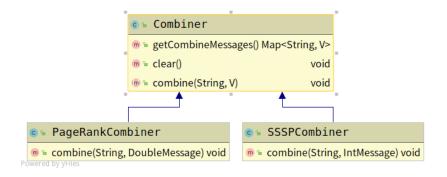


图 3.5: Combiner 及其子类 UML 图

Combiner 及其子类用作将属性进行

# 第4章 实验心得

可以分享您在实验环境搭建、程序编写和调试以及结果分析过程中遇到的问题和解决方法。

# 参考文献

[1] Malewicz, G., Austern, M. H., Bik, A. J., Dehnert, J. C., Horn, I., Leiser, N., & Czajkowski, G. (2010, June). Pregel: a system for large-scale graph processing. In Proceedings of the 2010 ACM SIGMOD International Conference on Management of data (pp. 135-146). ACM.